



**PHENIKAA UNIVERSITY**  
**School of Computing**

# Lập trình phân tích dữ liệu với Python

## DATA PREPROCESSING FOR TABULAR DATA

Giảng viên: TS.Nguyễn Ngọc Giang  
Contact: [giang.nguyenngoc@phenikaa-uni.edu.vn](mailto:giang.nguyenngoc@phenikaa-uni.edu.vn)

# Phần 1: Tổng quan

## Tại sao cần tiền xử lý dữ liệu?

- **Nguyên lý cốt lõi:** "Garbage In, Garbage Out"
- **Thực trạng dữ liệu thô (Raw Data):**
  - **Thiếu sót (Incomplete):** Thiếu giá trị, thiếu thuộc tính.
  - **Nhiều (Noisy):** Chứa lỗi, sai số, điểm ngoại lai (outliers).
  - **Không nhất quán (Inconsistent):** Sai lệch về mã, định dạng, trùng lặp.
- **Mục tiêu:** Chuyển đổi dữ liệu thô thành dạng "sạch", chuẩn hóa để máy tính có thể hiểu và học hiệu quả.

## Quy trình Tiền xử lý dữ liệu

- **Làm sạch dữ liệu (Data Cleaning):** Xử lý Missing values, Outliers, Duplicates.
- **Kỹ thuật xây dựng đặc trưng (Feature Engineering):**
  - *Biến đổi (Transformation):* Scaling, Encoding.
  - *Tạo mới (Construction):* Tạo biến từ miền tri thức.
  - *Giảm chiều (Reduction):* Selection & Extraction.

# Phần 2: Data Cleaning

## Dữ liệu khuyết thiếu (Missing Values) - Phân loại

- **Nhận diện:** NaN, Null, None, khoảng trắng, hoặc ký tự giữ chỗ (?, -999).
- **3 Cơ chế khuyết thiếu:**
  1. **MCAR (Missing Completely At Random):** Ngẫu nhiên hoàn toàn (không liên quan đến dữ liệu).
  2. **MAR (Missing At Random):** Ngẫu nhiên có điều kiện (VD: Nữ giới thường bỏ trống mục cân nặng hơn nam giới).
  3. **MNAR (Missing Not At Random):** Có quy luật/nguyên nhân ẩn (VD: Cảm biến bị hỏng ở nhiệt độ cao  $\rightarrow$  thiếu dữ liệu nhiệt độ cao).

# Chiến lược xử lý Missing Values

## • Phương pháp 1: Xóa bỏ (Deletion)

- Xóa dòng (Listwise): Khi số lượng mẫu thiếu rất ít ( $<5\%$ ).
- Xóa cột (Dropping Variable): Khi cột đó thiếu quá nhiều ( $>50-70\%$ ) hoặc không quan trọng.

## • Phương pháp 2: Điền khuyết (Imputation)

- *Simple Imputer*: Mean (Trung bình), Median (Trung vị - tốt khi có outliers), Mode (Yếu vị - cho biến phân loại).
- *Advanced Imputer*: Dùng KNN hoặc Regression để dự đoán giá trị thiếu dựa trên các cột khác.

## **Dữ liệu nhiễu và Ngoại lai (Outliers)**

- **Định nghĩa:** Các điểm dữ liệu khác biệt quá xa so với phần còn lại.
- **Cách phát hiện:**
  - Trực quan hóa: Boxplot (Biểu đồ hộp), Scatter plot.
  - Thống kê: Z-Score (vượt quá  $\pm 3\sigma$ ), IQR (Interquartile Range).
- **Cách xử lý:**
  - Xóa bỏ: Nếu xác định là lỗi nhập liệu/đo đạc.
  - Capping/Flooring (Winsorization): Gán về giá trị trần/sàn quy định.
  - Giữ nguyên: Nếu là hiện tượng thật (VD: Gian lận tài chính).

## Trùng lặp và Không nhất quán

- **Xử lý trùng lặp (Duplicates):**
  - Dòng trùng hoàn toàn: Xóa để tránh Overfitting (mô hình học vẹt).
  - Trùng ID nhưng khác thông tin: Cần kiểm tra lại quy trình thu thập.
- **Xử lý không nhất quán:**
  - Chuẩn hóa chính tả/Văn bản (VD: "tp hcm", "HCMC" -> "TP.HCM").
  - Đồng bộ định dạng ngày tháng (DD/MM/YYYY).
  - Quy đổi đơn vị đo lường (USD sang VND, kg sang lbs).

# Phần 3: Feature Engineering

# BIẾN ĐỔI (TRANSFORMATION)

- Chuẩn hóa dữ liệu số (Feature Scaling)
  - **Tại sao cần chuẩn hóa?**
    - Đưa các đặc trưng về cùng một phạm vi giá trị.
    - Cần thiết cho thuật toán dựa trên khoảng cách (KNN, K-Means) và tối ưu hóa (Gradient Descent).
  - **Standardization (Z-score):**
    - Đưa về Mean = 0, Std = 1.
    - Tốt cho dữ liệu phân phối chuẩn, chịu được outlier tốt hơn Min-Max.
  - **Min-Max Normalization:**
    - Đưa về đoạn [0, 1].
    - Giữ nguyên phân phối gốc, dùng cho Neural Networks, Image Processing.

# BIẾN ĐỔI (TRANSFORMATION)

- Mã hóa biến phân loại (Categorical Encoding)
  - **Vấn đề:** Máy tính chỉ hiểu con số, không hiểu chuỗi ký tự.
  - **Biến định danh (Nominal - Không thứ tự):** Màu (Đỏ, Xanh), Giới tính.
    - > Dùng **One-Hot Encoding**: Tạo cột nhị phân riêng biệt (Red: [1,0], Blue: [0,1]).
  - **Biến thứ bậc (Ordinal - Có thứ tự):** Đánh giá (Kém, Khá, Tốt).
    - > Dùng **Label/Ordinal Encoding**: Gán số thứ tự (Kém=0, Khá=1, Tốt=2).

# BIẾN ĐỔI (TRANSFORMATION)

- Rời rạc hóa (Binning/Discretization)
  - **Khái niệm:** Chuyển đổi biến liên tục thành biến phân loại (khoảng giá trị).
  - **Ví dụ:** Tuổi (18, 25, 60...) -> Nhóm tuổi (Thanh niên, Trung niên, Cao tuổi).
  - **Lợi ích:**
    - Giảm ảnh hưởng của nhiễu nhỏ.
    - Giúp mô hình tuyến tính nắm bắt được mối quan hệ phi tuyến tính đơn giản.

# TẠO MỚI (CONSTRUCTION)

- **Feature Construction - Sức mạnh của Domain Knowledge**
  - **Định nghĩa:** Tạo ra các biến mới mang nhiều thông tin dự báo hơn so với biến thô ban đầu.
  - **Mục tiêu:** Làm nổi bật các mẫu (patterns) trong dữ liệu giúp mô hình học dễ dàng hơn.
  - **Nguyên tắc:** Dựa trên sự thấu hiểu nghiệp vụ (Business Understanding).

# TẠO MỚI (CONSTRUCTION)

- **Dựa trên thời gian (Temporal Features):**
  - Từ Timestamp -> Tách ra: Giờ trong ngày (Sáng/Chiều), Thứ trong tuần, Có phải ngày lễ/cuối tuần không?
- **Đặc trưng tương tác (Interaction Features):**
  - Phép toán: Tổng doanh thu / Số lượng = Đơn giá trung bình.
  - Tỷ lệ: Nợ / Thu nhập (DTI Ratio trong ngân hàng).
- **Đặc trưng tổng hợp (Aggregated Features):**
  - Tính trung bình/max/min giao dịch trong 3 tháng gần nhất của khách hàng.

## GIẢM CHIỀU (REDUCTION)

- **Vấn đề "Lời nguyền số chiều" (Curse of Dimensionality)**
  - **Vấn đề:** Khi số lượng cột (features) quá lớn:
    - Dữ liệu trở nên thưa thớt (sparse).
    - Mô hình dễ bị Overfitting (học quá khớp).
    - Thời gian huấn luyện tăng vọt.
  - **Giải pháp:** Giảm số chiều nhưng giữ lại thông tin quan trọng nhất.

# GIẢM CHIỀU (REDUCTION)

- **Feature Selection (Lựa chọn đặc trưng)**

- **Định nghĩa:** Chọn ra tập con các cột tốt nhất, giữ nguyên giá trị gốc.
- **Các nhóm phương pháp:**
  - **Filter (Lọc):** Dựa trên thống kê (Tương quan - Correlation Matrix, Variance Threshold). Nhanh, độc lập với mô hình.
  - **Wrapper (Bao bọc):** Thử sai trên mô hình (Recursive Feature Elimination). Chậm nhưng chính xác.
  - **Embedded (Nhúng):** Tích hợp trong quá trình huấn luyện (Lasso Regression, Feature Importance từ Random Forest).

# GIẢM CHIỀU (REDUCTION)

- **Feature Extraction (Trích xuất đặc trưng)**

- **Định nghĩa:** Biến đổi dữ liệu sang không gian mới ít chiều hơn (tạo cột mới là tổ hợp của cột cũ).
- **Kỹ thuật tiêu biểu: PCA (Principal Component Analysis).**
  - Tìm các trục chính sao cho phương sai dữ liệu lớn nhất.
  - Dùng để nén dữ liệu và trực quan hóa (từ n-chiều về 2D/3D).

# GIẢM CHIỀU (REDUCTION)

| Tiêu chí        | Feature Selection                    | Feature Extraction             |
|-----------------|--------------------------------------|--------------------------------|
| Hành động       | Chọn lọc cột có sẵn                  | Tạo cột tổng hợp mới           |
| Ý nghĩa         | Giữ nguyên ý nghĩa vật lý (VD: Tuổi) | Mất ý nghĩa gốc (VD: PC1, PC2) |
| Tính giải thích | Cao                                  | Thấp                           |
| Ứng dụng        | Khi cần xác định yếu tố ảnh hưởng    | Khi cần nén tối đa             |

# Phần 4: Tổng kết

## Cạm bẫy Data Leakage

- **Định nghĩa:** Thông tin từ tập kiểm thử (Test set) bị rò rỉ vào quá trình huấn luyện.
- **Lỗi sai hay gặp:** Tính toán Mean, Max, Min để điền khuyết hoặc chuẩn hóa trên **TOÀN BỘ** dữ liệu trước khi chia Train/Test.

# Cạm bẫy Data Leakage

- **Quy trình đúng:**

1. Chia dữ liệu -> Train set & Test set
2. Fit (học tham số) chỉ trên Train set
3. Transform (áp dụng) trên cả Train set và Test set

- Tiền xử lý chiếm 60-80% thời gian dự án.
- Thứ tự thực hiện: **Hiểu dữ liệu -> Làm sạch -> Tạo đặc trưng -> Chọn lọc đặc trưng -> Xây dựng mô hình.**
- Không có công thức chung: Phải thử nghiệm (Trial & Error) để tìm ra phương pháp tốt nhất cho từng bài toán.



**PHENIKAA UNIVERSITY**  
**School of Computing**

# Thank You!

## Q&A