

Lập Trình Cho Trí Tuệ Nhân Tạo

Logistic Regression – Hồi Quy Logistic

Nguyễn Ngọc Giang
giang.nguyenngoc@phenikaa-uni.edu.vn

Bài học hôm nay

- **Supervised learning (học có giám sát)**
 - Regression (Hồi Quy)
 - Linear Regression (Hồi Quy Tuyến Tính)
 - Gradient Descent Algorithm
 - **Classification (Phân loại)**
 - **Logistic Regression (Hồi quy Logistic)**
 - Unsupervised learning (học không giám sát)
 - Clustering (Phân nhóm/cụm)
 - Association (Liên kết)
 - Semi-supervised Learning (Học bán giám sát)
 - Reinforcement Learning (Học tăng cường)
-

Tổng quan

1. Ví dụ bài toán phân loại
 2. Phân loại (phân lớp)
 3. Các bước giải quyết bài toán phân loại
 4. Logistic Regression
 5. Thước đo mô hình phân loại
 6. Ví dụ các bước giải
 7. Ứng dụng thực tế
-

1. Ví dụ



Nhóm biết bay



Nhóm biết bơi



Nhóm biết bò





Nhóm....?

1. Ví dụ


$$Y = aX + b$$

$$Y = aX + b$$




1. Ví dụ

$$Y = ?$$



Classification

$$Y = aX + b$$




Regression

1. Ví dụ




Regression

What is the temperature going to be tomorrow?



Classification

Will it be Cold or Hot tomorrow?




2. Phân loại (phân lớp)

- Là một quá trình của việc chia các lớp dữ liệu thành các nhóm hay loại khác nhau bằng việc gắn nhãn.
 - Là kỹ thuật của việc phân loại các quan sát (mẫu) thành các loại khác nhau.
 - Về cơ bản, chúng ta xử lý dữ liệu, phân tích dữ liệu dựa trên một số điều kiện và cuối cùng chúng ta phân chia dữ liệu đấy thành các loại hay nhóm đã được gắn nhãn trước.
-


2. 1 Các dạng bài toán phân loại

1. Binary Classification: Là bài toán phân loại hai nhóm khác nhau. Ví dụ: phân loại email là thư rác hoặc không phải thư rác.



2. 1 Các dạng bài toán phân loại

2. Multi-class Classification:
Là bài toán phân loại nhiều hơn hai nhóm khác nhau.
Ví dụ: phân loại động vật vào các loài khác nhau.




Multi-class classification


2. 1 Các dạng bài toán phân loại

3. Multi-label Classification: Là bài toán phân loại một điểm dữ liệu vào nhiều nhãn khác nhau. Ví dụ: phân loại sản phẩm vào nhiều danh mục khác nhau.


Binary Classification



Multiclass Classification




Multilabel Classification



2. 1 Các dạng bài toán phân loại

4. Imbalanced Classification: Là bài toán phân loại một lượng lớn các điểm dữ liệu thuộc một nhóm và một lượng nhỏ các điểm dữ liệu thuộc nhóm còn lại.

Ví dụ: phân loại các bệnh nhân là người bình thường hoặc ung thư, trong đó số lượng bệnh nhân ung thư rất ít.



3. Các bước giải quyết bài toán phân loại

- Xây dựng bài toán (mô hình hóa bài toán dưới dạng toán học)
 - Thu thập và chuẩn bị dữ liệu.
 - Chọn và trích xuất các đặc trưng
 - Chọn mô hình phù hợp: Logistic Regression, Decision Tree, SVM, Random Forest
 - Chia dữ liệu thành tập train và tập test
 - Huấn luyện mô hình dựa vào tập train và điều chỉnh các siêu tham số
 - Đánh giá mô hình dựa vào tập test dùng các chỉ số như accuracy, precision, recall
 - Triển khai mô hình vào thực tế.
-

4. Logistic Regression

- Là một mô hình **phân loại nhị phân** trong học có giám sát

Phân loại nhị phân là bài toán phân loại có biến mục tiêu gồm hai nhãn $\{0, 1\}$. Trong đó nhãn 1 là tích cực (*positive*) và nhãn 0 là tiêu cực (*negative*). Nhãn *tích cực* ở đây hàm chứa ý nghĩa xảy ra sự kiện và *tiêu cực* là sự vắng mặt của sự kiện. Mục tiêu của phân loại nhị phân là dự báo xác suất xảy ra hoặc vắng mặt của sự kiện lần lượt tương ứng với nhãn 1 và 0. Tổng của hai xác suất này bằng 1:


$$P(y = 1|\mathbf{x}, \mathbf{w}) + P(y = 0|\mathbf{x}, \mathbf{w}) = 1$$

Trong công thức trên thì $P(y = 1|\mathbf{x})$ là xác suất có điều kiện, nó thể hiện xác suất của *tích cực* tại một quan sát $\mathbf{x}$ ứng với một mô hình cụ thể có trọng số $\mathbf{w}$. Giá trị của xác suất này nằm trong khoảng $[0, 1]$. Chính vì thế trong hồi qui tuyến tính chúng ta sẽ đề xuất một hàm giả thuyết $0 \leq h_{\mathbf{w}}(\mathbf{x}) \leq 1$ để dự báo xác suất. Hàm này là hàm Sigmoid hoặc hàm Logistic mà chúng ta sẽ tìm hiểu ở mục sau.

4. 1 Hàm Sigmoid

- Mô hình hồi qui Logistic là sự tiếp nối ý tưởng của hồi qui tuyến tính vào các bài toán phân loại. Từ đầu ra của hàm tuyến tính chúng ta đưa vào hàm Sigmoid để tìm ra phân phối xác suất của dữ liệu.
- Hàm Sigmoid thực chất là một hàm biến đổi phi tuyến dựa trên công thức:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



4. 1 Hàm Sigmoid

- Hàm Sigmoid có hình dạng là một đường cong chữ S và **đơn điệu tăng**. Chính vì thế nên nó còn có tên một tên gọi khác là hàm chữ S. Một vài tài liệu còn gọi nó là **hàm Logistic** đại diện cho hồi qui Logistic.

$$\lim_{x \rightarrow +\infty} \sigma(x) = \lim_{x \rightarrow +\infty} \frac{1}{1 + e^{-x}} = 1$$

$$\lim_{x \rightarrow -\infty} \sigma(x) = \lim_{x \rightarrow -\infty} \frac{1}{1 + e^{-x}} = 0$$

4.2 Biểu diễn Logistic Regression

Quay trở lại với bài toán hồi qui tuyến tính. Với 2 biến đầu vào dự báo là $\mathbf{x} = (1, x_1, x_2)$ ta thu được một hàm hồi qui:

$$\hat{y} = g(x) = w_0 + w_1x_1 + w_2x_2 = \mathbf{w}^T \mathbf{x}$$

Ở đây $\mathbf{w} = (w_0, w_1, w_2)$ là véc tơ dòng của các hệ số hồi qui.


Chuyển tiếp giá trị này qua hàm *Sigmoid* để dự báo xác suất và tạo tính phi tuyến cho mô hình hồi qui:

$$P(y = 1|\mathbf{x}; \mathbf{w}) = \sigma(\mathbf{w}^T \mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}}$$

4.3 Ví dụ

Dự đoán khách hàng lựa chọn 1 sản phẩm


- Input thông tin của khách hàng
- **Output = 1** nếu khách hàng lựa chọn sản phẩm, **Output = 0** nếu khách hàng không lựa chọn



4.3 Ví dụ

Dự đoán khách hàng lựa chọn 1 sản phẩm


- Input thông tin của khách hàng
- **Output = 1** nếu khách hàng lựa chọn sản phẩm, **Output = 0** nếu khách hàng không lựa chọn



4.3 Ví dụ

Dự đoán khách hàng lựa chọn 1 sản phẩm


- Input thông tin của khách hàng
- **Output = 1** nếu khách hàng lựa chọn sản phẩm, **Output = 0** nếu khách hàng không lựa chọn



4.3 Ví dụ

Dự đoán khách hàng lựa chọn 1 sản phẩm

- Input thông tin của khách hàng
- **Output = 1** nếu khách hàng lựa chọn sản phẩm, **Output = 0** nếu khách hàng không lựa chọn




4.3 Ví dụ

Dự đoán khách hàng lựa chọn 1 sản phẩm

- Input thông tin của khách hàng
- **Output = 1** nếu khách hàng lựa chọn sản phẩm, **Output = 0** nếu khách hàng không lựa chọn

$$p(x) = \frac{1}{1 + e^{-(ax+b)}}$$



5) Thước đo mô hình phân loại

- Độ chính xác (*accuracy*): Thước đo thông dụng nhất của mô hình phân loại.
 - Độ chuẩn xác (*precision*): Thước đo tỷ lệ dự báo đúng được tính trên mẫu được dự báo là *dương tính* (*positive*) và trường hợp áp dụng chúng.
 - Độ nhạy (*recall*), tương tự như *độ chuẩn xác* nhưng được tính trên tỷ lệ của những mẫu thực tế là *dương tính*.
 - f1 score: Trung bình điều hoà của *độ chuẩn xác* và *độ nhạy*. Trường hợp nào thì nên áp dụng chúng thay cho *độ chuẩn xác*.
-

5) Thước đo mô hình phân loại

Giả sử ta xây dựng mô hình phân loại nợ xấu.

Mã khách hàng	Độ tuổi	Giới tính	Thu nhập hàng năm (triệu VNĐ)	Số lần vay trong năm	Tổng số nợ hiện tại (triệu VNĐ)	Số lần thanh toán trễ hạn trong 6 tháng qua	Nợ xấu
001	28	Nữ	400	2	2.5	0	Không
002	35	Nam	800	4	4.2	1	Có
003	42	Nữ	600	3	3.1	0	Không
004	23	Nam	300	1	1.8	2	Có
005	46	Nữ	900	5	6.5	0	Có

5) Thước đo mô hình phân loại

- Nhãn gồm:
 - Có nợ xấu, hay BAD, hoặc Dương tính (positive) hoặc là 1
 - Không nợ xấu, hay GOOD, hoặc Âm tính (negative) hoặc là 0
- Mô hình cho ra kết quả như sau:

Predict/Actual		Actual	
		BAD (Positive)	GOOD (Negative)
Predict	BAD (Positive)	55 (TP - True Positive)	50 (FP - False Positive)
	GOOD (Negative)	45 (FN - False Negative)	850 (TN - True Negative)
Total		100	900

5.1) Độ chính xác (accuracy)

- Là khái quát tỷ lệ các trường hợp được dự báo đúng trên tổng số các trường hợp
- Độ chính xác giúp ta đánh giá hiệu quả dự báo của mô hình trên một bộ dữ liệu.
- Độ chính xác càng cao thì mô hình của chúng ta càng tốt.

$$\text{Accuracy} = \frac{TP + TN}{\text{total sample}} = \frac{55 + 850}{1000} = 90.5\%$$

5.1) Độ chính xác (accuracy)

- Độ chính xác khá trực quan và dễ hiểu, thường dùng trong những bài toán phân loại không xảy ra mất cân bằng dữ liệu.
- Tuy nhiên ta dễ bị ngộ nhận trong bài toán mất cân bằng dữ liệu.
 - Vd: Bài toán phân loại ung thư thì cứ trong 1000 mẫu chỉ có khoảng 10 mẫu là dương tính. Nếu mô hình dự đoán 1000 mẫu đều là âm tính sẽ có độ chính xác đạt 99% trong khi mô hình không phát hiện được trường hợp ung thư nào.
- Ngoài ra, độ chính xác đánh giá trên toàn bộ các nhãn, không quan tâm đến tầm quan trọng của từng nhãn. VD, bài toán nợ xấu, phát hiện 1 hồ sơ nợ xấu quan trọng hơn việc chúng ta phát hiện đúng một hồ sơ thông thường

5.2) Độ chuẩn xác (precision)

- Độ chuẩn xác trả lời cho câu hỏi trong các trường hợp được dự báo là dương tính thì có bao nhiêu trường hợp là đúng ?
- Độ chuẩn xác càng cao thì mô hình của chúng ta càng tốt trong việc phân loại hồ sơ BAD.

$$\text{Precision} = \frac{TP}{\text{total predicted positive}} = \frac{TP}{TP + FP} = \frac{55}{55 + 50} = 52.4\%$$

Trong ví dụ trên độ chuẩn xác đạt 52.4% có ý nghĩa rằng trong các hồ sơ được dự báo là BAD thì có 52.4% các hồ sơ được dự báo đúng.

5.3) Độ phủ (recall)

- Độ phủ đo lường tỷ lệ dự báo chính xác các trường hợp dương tính trên toàn bộ các mẫu thuộc nhóm dương tính.

$$\text{Recall} = \frac{TP}{\text{total actual positive}} = \frac{TP}{TP + FN} = \frac{55}{55 + 45} = 55\%$$

- Có ý nghĩa gần tương tự như độ chuẩn xác, có cùng tử số nhưng có một chút khác biệt về mẫu số trong công thức tính toán dựa trên nhóm dương tính.

5.4) F1 Score

- là trung bình điều hòa giữa độ chuẩn xác và độ phủ. Do đó nó là chỉ số đại diện trong việc đánh giá tỷ lệ dự báo đúng của các trường hợp mẫu dương tính (hồ sơ BAD).

$$f_1 = \frac{2}{\text{precision}^{-1} + \text{recall}^{-1}} = \frac{2}{0.524^{-1} + 0.55^{-1}} = 53.7\%$$

Trong trường hợp $\text{precision} = 0$ hoặc $\text{recall} = 0$ ta qui ước $f_1 = 0$.

- Giá trị của F1 score luôn nằm trong khoảng độ chuẩn xác và độ phủ. Do đó khi mà độ chuẩn xác và độ phủ quá chênh lệch thì F1 score sẽ cân bằng được cả hai giá trị này và giúp ta đưa ra một đánh giá khách quan hơn.

5.4) F1 Score

- Precision = 91.6% → Mô hình tốt, quá lạc quan
- Recall = 55% → Mô hình không tốt, quá bi quan
- F1 score = 69% → Sức mạnh trung bình, đánh giá khách quan hơn

Predict/Actual		Actual		
		BAD (Positive)	GOOD (Negative)	
Predict	BAD (Positive)	55 (TP - True Positive)	5 (FP - False Positive)	precision=55/(55+5)=91.6%
	GOOD (Negative)	45 (FN - False Negative)	895 (TN - True Negative)	
Total		100	900	
		recall=55/(55+45)=55%		

6) Example

- Phân loại liệu một người có mua hàng hay không dựa trên độ tuổi và thu nhập của họ.

Age	Income (k)	Purchased
22	30	No
25	45	No
47	55	Yes
52	85	Yes
46	25	No
56	62	Yes
48	48	Yes
32	36	No
41	52	Yes
39	44	No



Age	Income (k)	Purchased
22	30	0
25	45	0
47	55	1
52	85	1
46	25	0
56	62	1
48	48	1
32	36	0
41	52	1
39	44	0

6) Example

- Chúng ta muốn ước lượng xác suất xảy ra của một sự kiện (trong trường hợp này là "Purchased" = 1) dựa trên các biến đầu vào.

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2)}}$$

- $P(Y = 1|X)$ là xác suất dự đoán.
 - X_1 là tuổi (Age).
 - X_2 là thu nhập (Income).
 - $\beta_0, \beta_1, \beta_2$ là các tham số của mô hình cần ước lượng.
-

6) Example

Trong thực tế, các tham số $\beta_0, \beta_1, \beta_2$ thường được ước lượng bằng phương pháp tối đa hóa hàm likelihood (Maximum Likelihood Estimation - MLE). Tuy nhiên, việc tính toán này khá phức tạp và thường được thực hiện bằng phần mềm hoặc công cụ tính toán.

Giả sử sau quá trình tính toán (dùng MLE) ta có được các tham số ước lượng là:

- $\beta_0 = -25.161$
 - $\beta_1 = 0.206$
 - $\beta_2 = 0.201$
-

6) Example

Sử dụng các tham số trên, chúng ta có thể tính toán xác suất "Purchased" cho từng cá nhân trong dataset. Ví dụ:

$$\begin{aligned} P(Y = 1|X_1 = 22, X_2 = 30) &= \frac{1}{1 + e^{-(-25.161 + 0.206 \times 22 + 0.201 \times 30)}} \\ &= \frac{1}{1 + e^{-(-25.161 + 4.532 + 6.03)}} = \frac{1}{1 + e^{-(-14.599)}} \approx 4.6 \times 10^{-6} \end{aligned}$$

Nếu xác suất tính được lớn hơn hoặc bằng 0.5, chúng ta dự đoán "Purchased" = 1 (Yes), ngược lại "Purchased" = 0 (No).

6) Example

- Giả sử đây là kết quả dự đoán

Confusion Matrix

	Predicted No	Predicted Yes
Actual No	5	0
Actual Yes	0	5

Age	Income (k)	Purchased (Actual)	Purchased (Predicted)
22	30	0	0
25	45	0	0
47	55	1	1
52	85	1	1
46	25	0	0
56	62	1	1
48	48	1	1
32	36	0	0
41	52	1	1
39	44	0	0

6) Example

Confusion Matrix

	Predicted No	Predicted Yes
Actual No	5	0
Actual Yes	0	5

Accuracy

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{5 + 5}{5 + 5 + 0 + 0} = 1.0$$

Precision

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{5}{5 + 0} = 1.0$$

Recall

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{5}{5 + 0} = 1.0$$

7. Ứng dụng

- Phân loại khách hàng dựa trên hành vi mua hàng

Số thứ tự	Số lần mua hàng	Tổng số tiền đã chi	Số lần đăng nhập	Số lần thực hiện đánh giá sản phẩm	Số lần tham gia khuyến mãi	Loại khách hàng
1	3	100 USD	10	5	2	Thường xuyên
2	1	50 USD	2	0	1	Có thể quay lại
3	2	20 USD	5	2	0	Thường xuyên
4	4	500 USD	20	10	5	Thường xuyên
5	1	10 USD	1	0	0	Khách mới

7. Ứng dụng

- Phân loại thư rác (spam) trong hộp thư đến của người dùng email

Số thứ tự	Tiêu đề email	Nội dung email	Đánh giá
1	"Trúng thưởng lớn"	"Chúc mừng bạn đã trúng giải độc đắc 10 triệu đồng"	Spam
2	"Hướng dẫn sử dụng sản phẩm"	"Xin chào, sản phẩm của bạn đã được gửi đến. Hãy xem video hướng dẫn để sử dụng sản phẩm."	Không phải spam
3	"Cập nhật thông tin tài khoản"	"Chào bạn, hãy cập nhật thông tin tài khoản của bạn để giữ an toàn."	Không phải spam
4	"Cơ hội du lịch miễn phí"	"Tham gia chương trình và nhận ngay cơ hội du lịch miễn phí đến Hawaii"	Spam
5	"Thông báo từ trường đại học"	"Chúng tôi muốn thông báo với bạn về việc đăng ký khoá học mới của trường đại học."	Không phải spam

7. Ứng dụng

Phân loại khách hàng tiềm năng: Bài toán này nhằm xác định khách hàng tiềm năng nào có thể trở thành khách hàng thực sự của công ty.

ID	Độ tuổi	Giới tính	Thu nhập hàng năm (triệu VNĐ)	Số lần mua hàng trong năm	Sở thích sản phẩm	Đánh giá chất lượng dịch vụ (trên 5)	Loại khách hàng
1	28	Nữ	500	4	Thời trang	4.7	Tiềm năng
2	35	Nam	1000	10	Đồ điện tử	4.2	Tiềm năng
3	42	Nữ	800	6	Đồ gia dụng	4.9	Tiềm năng
4	50	Nam	1500	8	Đồ điện tử	4.8	Khách hàng thân thiết
5	25	Nữ	350	2	Thời trang	3.9	Tiềm năng
6	40	Nam	1200	4	Đồ thể thao	4.6	Tiềm năng

7. Ứng dụng

Phân loại giao dịch tài chính thành hai loại, giao dịch hợp lệ và giao dịch gian lận

ID	Thời gian giao dịch	Số tiền	Địa điểm	Ngân hàng	Loại giao dịch	Đánh giá người dùng	Giao dịch hợp lệ
1	2022-01-01 08:00:00	5000000	Hà Nội	Vietcombank	Rút tiền	4.5	1
2	2022-01-02 13:30:00	10000000	Hồ Chí Minh	Techcombank	Chuyển khoản	3.2	0
3	2022-01-05 10:00:00	8000000	Hải Phòng	Agribank	Thanh toán	4.9	1
4	2022-01-10 15:45:00	2000000	Đà Nẵng	ACB	Rút tiền	4.7	1
5	2022-01-12 11:20:00	15000000	Hà Nội	Vietinbank	Chuyển khoản	4.1	0
6	2022-01-14 09:30:00	5000000	Hồ Chí Minh	Sacombank	Rút tiền	4.8	1
7	2022-01-20 16:15:00	12000000	Đà Nẵng	Techcombank	Chuyển khoản	3.7	0

8. Link thực hành trên lớp và bài tập về nhà

- Link Google Colab thực hành trên lớp trong đó có cả bài tập về nhà.
 - https://colab.research.google.com/drive/1fMl8ugseFQqW7StJlc3CfRNi5dVith_2?usp=sharing
-

9. References

1. <https://www.coursera.org/learn/machine-learning>
 2. <https://www.youtube.com/c/TriTh%E1%BB%A9cNh%C3%A2nLo%E1%BA%A1i>
 3. <https://machinelearningcoban.com/>
 4. Nhập môn Trí Tuệ Nhân Tạo và Khoa Học Dữ Liệu (Học Máy, Phạm Tiến Lâm, Phenikaa University)
 5. <http://raminrastin.com/uncategorized/simple-machine-learning-workflow/>
 6. <https://www.youtube.com/watch?v=F3YoC5A6Avg>
 7. https://phamdinhhkhanh.github.io/deepai-book/ch_ml/index_classification.html
-