

Lập Trình Cho Trí Tuệ Nhân Tạo

Unsupervised Learning – Học không giám sát

Nguyễn Ngọc Giang
giang.nguyenngoc@phenikaa-uni.edu.vn


Tổng quan

- Supervised learning (học có giám sát)
 - Regression (Hồi Quy)
 - Classification (Phân loại)
 - Unsupervised learning (học không giám sát)
 - Clustering (Phân nhóm/cụm)
 - Association (Liên kết)
 - Semi-supervised Learning (Học bán giám sát)
 - Reinforcement Learning (Học tăng cường)
-


Mô hình học máy

Tất cả các mô hình học máy đều có thể xem là các mô hình dự đoán:

- Các mô hình học máy cổ điển: Unsupervised learning và supervised learning.
- Mô hình ensemble: Random forest; bagging; boosting
- Reinforcement learning: Monte Carlo Tree Search (MCTS) : alpha GO (2016)
- Neural networks và Deep learning

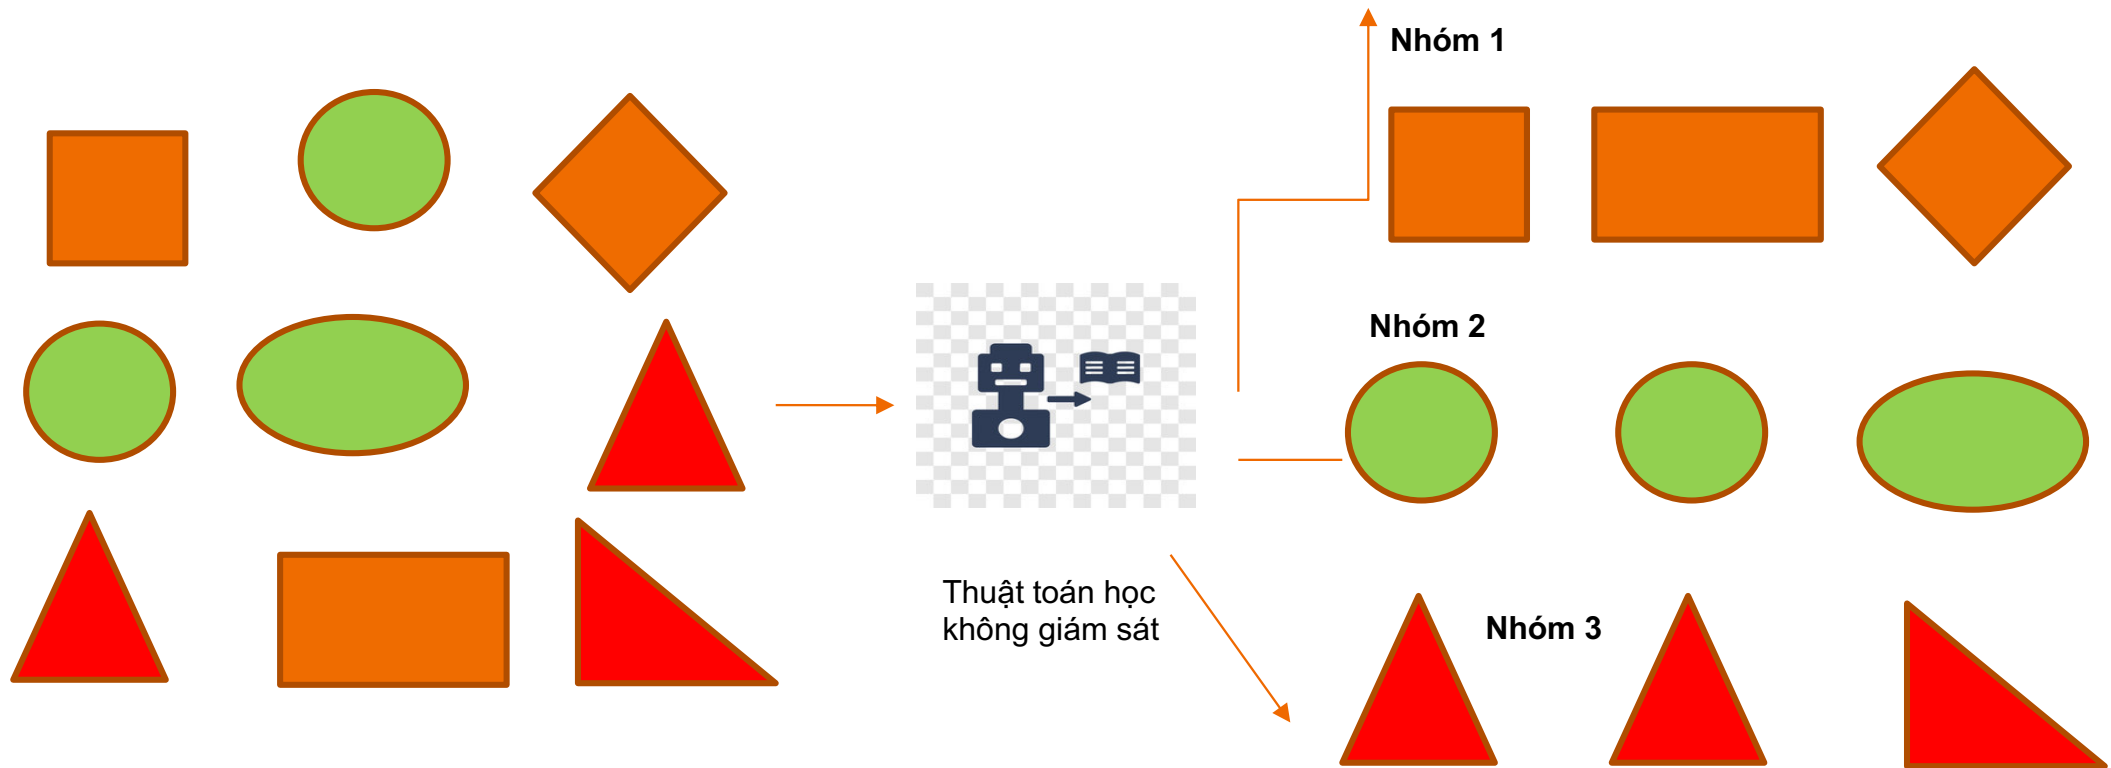


1. Học không giám sát




1. Học không giám sát

Ta có một tập dữ liệu không gắn nhãn, tìm quan hệ ẩn trong dữ liệu.



1. Học không giám sát

Màu xanh lá cây, có 4 cạnh, có 4 góc.



Dữ liệu mới



UNSUPERVISED
FUTURE TECHNOLOGY

Mô hình dự đoán

Sẽ thuộc
nhóm nào
???

2. Giám sát và không giám sát

- Điểm giống:
 - Cần dữ liệu đầu vào để xây dựng mô hình.
 - Đều được dùng cho mô hình dự đoán.
- Điểm khác nhau:
 - Học giám sát: Có gắn nhãn/có kết quả tương ứng với dữ liệu thuộc tính. (Có đủ Y và X)
 - Học không giám sát. Chỉ có dữ liệu thuộc tính (Chỉ có X)

3. Phân nhóm (cụm)


- Cho ba nhóm về các chủ đề: Sport, Fashion, Nature.
 - Sport: football, volleyball, badminton, table tennis (Ping-Pong)
 - Fashion: clothes; jeans, sock, hat, shoes
 - Nature: soil, ocean, wind, human, tree, forest
- model, athlete, lion?
 - model → Fashion
 - Athlete -> Sport
 - Lion -> Nature

3. Phân nhóm (cụm)



- Love, like, enjoy, passion; dislike, hate , angry, disappointed, frustrated
- Nhóm 1: Love, like, enjoy, passion
- Nhóm 2: dislike, hate, angry, disappointed, frustrated

3. Phân nhóm (cụm)

Có thể phân làm bao nhiêu cụm/nhóm.




3. Phân nhóm (cụm)



3.1 Vấn đề đặt ra?

- Ta có một tập dữ liệu, chúng ta có thể tìm ra các nhóm/cụm trong dữ liệu này không?
- Làm thế nào chúng ta có thể quyết định có bao nhiêu nhóm?
- Liệu có những nhóm con trong một nhóm hay không?

Motivating Example




3.2 Định nghĩa nhóm/ cụm (cluster)

Nhóm/cụm: là một tập con các đối tượng trong dữ liệu :

- Các đối tượng trong cụm là giống nhau/tương tự.
- Các đối tượng ở 2 cụm khác nhau là khác nhau/ không tương tự

Một vài tính chất liên quan đến cụm:

- Trung tâm của cụm (cluster center)
- Kích thước của cụm (cluster size)
- Mật độ của cụm (Cluster density)
- Mô tả cụm (Cluster descriptions)



3.3 Quá trình phân nhóm (clustering)


- Quá trình phân nhóm/cụm là: một tiến trình/quá trình để chia các đối tượng trong một tập dữ liệu thành các nhóm/ cụm.
- Như vậy: Thuật toán phân nhóm/phân cụm cũng có thể gọi là Phân lớp không giám sát (unsupervised classification) hay Học không giám sát (Unsupervised learning).
 - Phải giải quyết vấn đề bằng cách tìm hiểu/xác định cấu trúc dữ liệu, mối quan hệ giữa các thuộc tính trong lớp dữ liệu không có thông tin về Nhãn

3.3 Quá trình phân nhóm (clustering)

- Việc phải làm
 - Xây dựng hàm tính độ tương tự
 - Xây dựng các tiêu chuẩn phân nhóm/cụm
 - Xây dựng mô hình cho cấu trúc nhóm dữ liệu
 - Xây dựng các thuật toán phân nhóm, xác định các điều kiện khởi tạo
- Chưa có phương pháp phân nhóm tối ưu cho mọi loại dữ liệu.
- Phương pháp phân nhóm dữ liệu vẫn là vấn đề mở, cần giải quyết những vấn đề phù hợp với nhiều dạng dữ liệu khác nhau.


3.4 Thuật toán phân nhóm

- Là quá trình phân chia dữ liệu thành một các nhóm dữ liệu thỏa mãn
 - Các đối tượng trong một nhóm thì giống nhau/ tương tự nhau
 - Các đối tượng thuộc các nhóm khác nhau thì khác nhau/ không tương tự nhau.
- Mục đích: Giải quyết vấn đề tìm kiếm, xác định các nhóm từ dữ liệu ban đầu không có nhãn.



3.4 Thuật toán phân nhóm

- Xác định được bản chất của các nhóm trong dữ liệu không có nhãn
- Phụ thuộc vào tiêu chí phân nhóm do người dùng đưa ra




<http://kdd.ics.uci.edu/databases/CorelFeatures/CorelFeatures.data.html>

3.4 Thuật toán phân nhóm

- Chia là 3 loại chính:
 - Partition (Chia nhỏ dữ liệu)
 - Hierarchical (Chia phân tầng)
 - Density (Chia theo mật độ)



3.4 Thuật toán phân nhóm



3.4.1 Hierarchical clustering

- Hierarchical clustering có thể được xây dựng bằng cách phân tách dữ liệu thành các cụm nhỏ hơn và kết hợp các cụm này để tạo ra các cụm lớn hơn.
- Hierarchical clustering có hai phương pháp chính là phân cụm trên (agglomerative) và phân cụm dưới (divisive).
 - Phương pháp phân cụm trên bắt đầu bằng cách xem mỗi điểm dữ liệu là một cụm riêng lẻ và sau đó liên tục gộp các cụm có độ tương đồng cao để tạo ra các cụm lớn hơn.
 - Phương pháp phân cụm dưới bắt đầu với toàn bộ dữ liệu được coi là một cụm duy nhất, sau đó liên tục chia nhỏ các cụm này thành các cụm nhỏ hơn.

3.4.1 Hierarchical clustering



3.4.1 Hierarchical clustering

- Các phương pháp hierarchical clustering sử dụng các độ đo tương đồng (similarity measures) để đánh giá mức độ giống nhau giữa các điểm dữ liệu hoặc các cụm.
- Các độ đo tương đồng phổ biến bao gồm khoảng cách Euclidean, khoảng cách Manhattan và khoảng cách cosine.
- Hierarchical clustering có thể được biểu diễn dưới dạng cây phân cấp (dendrogram), trong đó mỗi nút trong cây đại diện cho một cụm và các cụm con của nó được biểu thị bởi các nhánh. Các cụm lớn hơn ở độ cao thấp hơn trong cây, trong khi các cụm nhỏ hơn nằm ở độ cao cao hơn. Cây phân cấp có thể được sử dụng để chọn số lượng cụm phù hợp cho dữ liệu.

3.4.1 Hierarchical clustering


- Pearson Correlation

$$\vec{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_m \end{bmatrix} \quad \text{and} \quad \vec{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}$$


$$C_{\text{pearson}}(\vec{x}, \vec{y}) = \frac{\sum_{j=1}^m (x_j - \bar{x})(y_j - \bar{y})}{\sqrt{[\sum_{j=1}^m (x_j - \bar{x})^2][\sum_{j=1}^m (y_j - \bar{y})^2]}}$$

$$\bar{x} = \frac{1}{m} \sum_{j=1}^m x_j$$

$$\bar{y} = \frac{1}{m} \sum_{j=1}^m y_j$$



$$+1 \geq \text{Pearson Correlation} \geq -1$$



3.4.1 Hierarchical clustering



- Cosine Correlation

$$\vec{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_m \end{bmatrix} \quad \vec{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}$$

$$C_{\text{cosine}}(\vec{x}, \vec{y}) = \frac{\frac{1}{m} \sum_{j=1}^m x_j \times y_j}{\|\vec{x}\| \times \|\vec{y}\|}$$

$$\vec{x} = \vec{y} \quad +1 \geq \text{Cosine Correlation} \geq -1 \quad \vec{x} = -\vec{y}$$

3.4.1 Hierarchical clustering




**Venn Diagram of
Clustered Data**




From <http://www.stat.unc.edu/postscript/papers/marron/Stat321FDA/RimalZempresentation.ppt>

3.4.2 Density clustering

- Density clustering (phân cụm mật độ) dựa trên mật độ của các điểm dữ liệu để phân chia chúng vào các cụm.
- Trong density clustering, các cụm được xác định bởi các vùng có mật độ cao của các điểm dữ liệu, được phân chia bởi các vùng có mật độ thấp hơn.
- Các vùng có mật độ cao được coi là các cụm, trong khi các vùng có mật độ thấp được coi là các khe hở giữa các cụm.



3.4.2 Density clustering




3.4.2 Density clustering

- Density clustering được sử dụng trong các bài toán mà không có số lượng cụm cần được xác định trước, và các cụm có thể có hình dạng và kích thước khác nhau.
- Density clustering có thể giải quyết được các vấn đề mà các phương pháp phân cụm khác như k-means không thể giải quyết, như các cụm có hình dạng không đều, các cụm có kích thước khác nhau, hoặc các cụm có mật độ không đồng nhất.
- Các thuật toán density clustering phổ biến:
 - DBSCAN (Density-Based Spatial Clustering of Applications with Noise)
 - OPTICS (Ordering Points To Identify the Clustering Structure).

3.4.2 Density clustering

- DBSCAN phân chia các điểm dữ liệu thành các cụm bằng cách xác định các vùng có mật độ cao và các khe hở giữa chúng.
- OPTICS có thể tìm ra các cụm có hình dạng phức tạp hơn bằng cách xác định các vùng có mật độ cao và đánh giá mức độ cách biệt giữa các vùng này.



3.4.3 Partition clustering

- Phổ biến nhất
- Partition clustering (phân cụm phân tán): Các cụm được tạo ra bởi gán các điểm dữ liệu vào nhóm sao cho tổng khoảng cách giữa các điểm dữ liệu trong cùng một cụm là nhỏ nhất có thể, và khoảng cách giữa các cụm là lớn nhất có thể.
- Cách chọn số lượng cụm:
 - Do người dung định nghĩa
 - Hoặc sử dụng phương pháp Elbow hoặc Silhouette.
- Yêu cầu:
 - Chọn thuật toán phân nhóm tốt
 - Chọn giá trị cho các tham số đầu vào.
 - Chọn một đơn vị đo “distance” trong dữ liệu. (Liên quan một phần đến chọn đặc trưng khi tính toán)



3.4.3 Partition clustering

- Thuật toán phân cụm phổ biến nhất K-means.
 - 1) Chọn số lượng cụm k
 - 2) Chọn ngẫu nhiên k điểm làm tâm của các cụm ban đầu.
 - 3) Gán mỗi điểm dữ liệu vào cụm gần nhất bằng cách tính khoảng cách từ mỗi điểm đến các tâm cụm và chọn cụm có tâm gần nhất.
 - 4) Cập nhật tâm của các cụm bằng cách lấy trung bình của tất cả các điểm dữ liệu trong cụm.
 - 5) Lặp lại bước 3 và 4 cho đến khi không có sự thay đổi đáng kể trong vị trí của các tâm cụm hoặc đã đạt đến số lần lặp tối đa được chỉ định.
- Phân cụm phân tán thường được sử dụng để phân loại các bài toán trong các lĩnh vực như marketing, phân tích dữ liệu khách hàng, nhận dạng hình ảnh và nhận dạng giọng nói.

3.4.3 Partition clustering

Thuật toán K-Means

- Đầu vào:
 - Cho tập giá trị $X = \{, , , \}$
 - Khởi tạo giá trị K
- Kết quả:
Các cụm $C = \{, \}$;



3.4.3 Partition clustering


Thuật toán K-Means

- Bước 1: chọn ngẫu nhiên K tâm cụm
- Bước 2: Tính toán khoảng cách từ các đối tượng đến các tâm cụm để phân hoạch dữ liệu (bằng cách gán mỗi đối tượng vào cụm nó gần nhất)
- Bước 3: Tính lại các tâm cụm mới trong mỗi cụm
- Bước 4: Lặp lại Bước 2 và Bước 3 cho đến khi thỏa mãn điều kiện: Tâm cụm ổn định và các đối tượng không dịch chuyển giữa các cụm.

3.4.3 Partition clustering

Thuật toán K-Means


- Khởi tạo tâm cụm



3.4.3 Partition clustering

Thuật toán K-Means


- Khởi tạo tâm cụm
- Gán các đối tượng cho cụm gần nhất



3.4.3 Partition clustering

Thuật toán K-Means


- Khởi tạo tâm cụm
- Gán các đối tượng cho cụm gần nhất
- Tính lại giá trị/vị trí tâm cụm



3.4.3 Partition clustering

Thuật toán K-Means


- Khởi tạo tâm cụm
- Gán các đối tượng cho cụm gần nhất
- Tính lại giá trị/vị trí tâm cụm
- Gán lại đối tượng với tâm cụm mới



3.4.3 Partition clustering

Thuật toán K-Means


- Cập nhật tâm cụm



3.4.3 Partition clustering

Thuật toán K-Means


- Gán lại đối tượng với các cụm
- Cập nhật lại tâm cụm



3.4.3 Partition clustering

Thuật toán K-Means


- Thỏa mãn điều kiện



3.4.3 Partition clustering

Thuật toán K-Means

Tuy nhiên, nếu khởi tạo không tốt sẽ dẫn đến phân nhóm/ cụm không hiệu quả



4. Link thực hành trên lớp và bài tập về nhà

- Link Google Colab thực hành trên lớp trong đó có cả bài tập về nhà.
- <https://colab.research.google.com/drive/1nMEK5Z-ltr3vuOBSaR5QAN0jQPIWgxUD?usp=sharing>

References

1. <https://www.coursera.org/learn/machine-learning>
 2. <https://www.youtube.com/c/TriTh%E1%BB%A9cNh%C3%A2nLo%E1%BA%A1i>
 3. <https://machinelearningcoban.com/>
 4. Nhập môn Trí Tuệ Nhân Tạo và Khoa Học Dữ Liệu (Học Máy, Trịnh Thành, Phenikaa University)
 5. <http://raminrastin.com/uncategorized/simple-machine-learning-workflow/>
 6. <https://www.youtube.com/watch?v=F3YoC5A6Avg>
 7. https://phamdinhhkhanh.github.io/deepai-book/ch_ml/index_classification.html
-